



Open Data + Mongo DB + R

Víctor Hugo Males

John Alexander Carvajal Agudelo



R Users Cali



Open Data + Mongo DB + R

- Introducción Open Data
- Ejemplo práctico OD + R
- Introducción MongoDB
- Ejemplo práctico MongoDB + R

The image features a dark blue background with abstract teal lines. In the top-left corner, there are several parallel lines that form a corner-like shape. In the bottom-right corner, there are several parallel lines that extend diagonally across the space.

Open Data

Open Data

Los datos abiertos u Open Data son información de libre acceso y gratuidad, que toman forma de archivos que respetan formatos interoperables.


Pueden ser de origen público: Servicios públicos, de colectividades o de comunas.

Pueden ser de origen privado: Provenientes de empresas o instituciones cuyos datos son concursables a proyectos de utilidad pública.

Características Open Data

- **Disponibilidad y acceso**: los datos deben estar disponibles mediante la descarga a través de Internet y en una forma legible.
- **Reutilización y redistribución**: los datos deben ser proporcionados bajo términos que permitan la reutilización y redistribución .
- **Participación universal**: Cualquier persona debe ser capaz de utilizar, reutilizar y redistribuirlos – no debe haber discriminación por campos de la actividad o en contra de personas o grupos.
- **Descriptivos y explicativos**: Deben contener una descripción de lo que contiene el archivo, condiciones de generación y descripción de cada campo del mismo

Tipos de archivos Open Data



Estadísticas

Gubernamentales

Cultural

Transporte

Públicos

Estado Financieros

Políticos

Medio Ambiente





Open Data + R



MongoDB

Principales cambios en la tecnología

- Masificación del uso de internet.
 - Surgimiento de las redes sociales.
 - Crecimiento exponencial de dispositivos móviles.
 - Posibilidad de distintos dispositivos conectados a internet (Internet de las cosas).
 - Interfaces de usuario más simples e intuitivas.
 - Cambios en las formas de procesamiento.
 - Fuerte baja en los costos de almacenamiento.
- 
- 





PINTEREST

SOCIAL SITE
THAT IS ALL ABOUT
DISCOVERY

LARGEST
OPPORTUNITIES



USERS ARE:

17% MALE
83% FEMALE

20
MILLION
ACTIVE USERS



TWITTER

MICRO BLOGGING
SOCIAL SITE
THAT LIMITS EACH
POST TO **140**
CHARACTERS

LARGEST
PENETRATION



BUT SPREADING
SLOWLY AND STEADILY

5,700 TWEETS
HAPPEN
EVERY
SECOND

241
MILLION
ACTIVE USERS



FACEBOOK

SOCIAL SHARING
SITE THAT HAS
1+ BILLION
USERS WORLDWIDE

LARGEST
OPPORTUNITIES



COMMUNICATING WITH
CONSUMERS
IN A NON-OBTRUSIVE WAY

USERS SHARE
1 MILLION LINKS
EVERY 20 MINUTES

1+
BILLION
ACTIVE USERS



INSTAGRAM

SOCIAL SHARING
SITE ALL AROUND
PICTURES
AND NOW 15 SECOND
VIDEOS

MANY BRANDS
ARE PARTICIPATING
THROUGH THE USE OF
#HASHTAGS

AND POSTING
PICTURES
CONSUMERS
CAN RELATE TO

MOST FOLLOWED
BRAND IS
NATIONAL
GEOGRAPHIC

200
MILLION
ACTIVE USERS



GOOGLE+

SOCIAL NETWORK
BUILT BY GOOGLE
THAT ALLOWS FOR
BRANDS
AND **USERS**
TO BUILD CIRCLES

NOT AS MANY
BRANDS
ACTIVE,
BUT THE ONES THAT ARE
TEND TO BE A
GOOD FIT WITH A
GREAT FOLLOWING

25-35 YEAR
OLDS
ARE THE MOST
ACTIVE

540
MILLION
ACTIVE USERS



LINKEDIN

BUSINESS
ORIENTED
SOCIAL NETWORKING SITE

BRANDS THAT ARE
PARTICIPATING
ARE **CORPORATE**
BRANDS
GIVING POTENTIAL AND
CURRENT ASSOCIATES
A PLACE TO **NETWORK**
& **CONNECT**



POWERS
50% OF THE
WORLD'S HIRES

300
MILLION
USERS

Statistics as of 4.25.2014 Designed by: Leverage - leveragenewagemedia.com



PINTEREST

SOCIAL SITE
THAT IS ALL ABOUT
DISCOVERY

LARGEST
OPPORTUNITIES



USERS ARE:

32% MALE
68% FEMALE

150
MILLION
ACTIVE USERS



TWITTER

MICRO BLOGGING
SOCIAL SITE
THAT LIMITS EACH
POST TO **140**
CHARACTERS

LARGEST
PENETRATION



BUT SPREADING
SLOWLY AND STEADILY

6,000 TWEETS
HAPPEN
EVERY
SECOND

313
MILLION
ACTIVE USERS



FACEBOOK

SOCIAL SHARING
SITE THAT HAS
1.86 BILLION
USERS WORLDWIDE

LARGEST
OPPORTUNITIES



COMMUNICATING WITH
CONSUMERS
IN A NON-OBTRUSIVE WAY

1.86
BILLION
ACTIVE USERS



INSTAGRAM

SOCIAL SHARING
SITE ALL AROUND
PICTURES
AND NOW 60 SECOND
VIDEOS

MANY BRANDS
ARE PARTICIPATING
THROUGH THE USE OF
#HASHTAGS

AND POSTING
PICTURES
CONSUMERS
CAN RELATE TO
(30 HASHTAGS
MAX PER PIC)

600
MILLION
ACTIVE USERS



GOOGLE+

SOCIAL NETWORK
BUILT BY GOOGLE
THAT ALLOWS FOR
BRANDS
AND **USERS**
TO BUILD CIRCLES

NOT AS MANY
BRANDS
ACTIVE,
BUT THE ONES THAT ARE
TEND TO BE A
GOOD FIT WITH A
GREAT FOLLOWING

GROWING RAPIDLY
NEW USERS EVERY DAY

375
MILLION
ACTIVE USERS



LINKEDIN

BUSINESS
ORIENTED
SOCIAL NETWORKING SITE

BRANDS THAT ARE
PARTICIPATING
ARE **CORPORATE**
BRANDS
GIVING POTENTIAL AND
CURRENT ASSOCIATES
A PLACE TO **NETWORK**
& **CONNECT**

79% OF USERS
ARE **35**
OR OLDER

467
MILLION
ACTIVE USERS

2014 Design by: Leverage, 2017 Design By: MarketingStrategyX.com

MongoDB

Es una bases de datos Open Source orienta a documentos diseñada para facilitar el desarrollo y la escalabilidad de las aplicaciones:

- No usan SQL como lenguaje de consulta
- Los datos almacenados no requieren estructuras fijas como tablas
- No garantizan consistencia
- Escalan horizontalmente
- Distribución, Auto-Replicación y Particionamiento
- Los datos se almacenan de forma atómica
- Posee distintos tipos de modelamiento

Características

- Soporta JSON, XML, BSON Modelos documentales con esquema dinámico
- Soporte de Índices
- Consultas Complejas
- Manejo de Seguridad Avanzada
- Almacenamiento de archivos de gran tamaño en su file system interno GridFS
- Búsquedas de texto(Full Text Search)
- Aggregation Framework y Map Reduce Nativo o con Hadoop

Tamaño máximo de un documento 16 MB

Tamaño máximo de una base de datos en 32 Bit es 2GB


```
    "_id" : NumberLong("722951307997401088"),
    "Text" : "RT @TaxisLibres4: Accidente de transito en la Cl 16 con Cr 100
. #traficocali @elpaiscali @TwiterosCali",
    "RetweetCount" : 1,
    "GeoLocation" : null,
    "Cuenta" : 1,
    "DateCreate" : "2016-04-20T21:53:18.000Z",
    "DateInsert" : "2016-04-27T00:15:47.066Z",
    "User" : {
      "isFavorited" : 0,
      "isRetweet" : 1,
      "isRetweetedByMe" : 0,
      "UserID" : NumberLong(185627001),
      "ScreenName" : "@HEFZIBA_CALI",
      "CreatedAt" : "2010-09-01T10:05:36.000Z",
      "Name" : "Luz Marina Ramirez",
      "Description" : "",
      "Followers" : 73,
      "Friends" : 206,
      "Location" : "Cali",
      "ProfileImageURL" : "http://pbs.twimg.com/profile_images/1127225
509/Karen__tia__y_mami__hot__normal.jpg",
      "TimeZone" : null,
      "URL" : null,
      "isGeoEnabled" : 0,
      "isVerified" : 0
    }
  }
```

```
<
  "_id" : ObjectId<"57310f4072f120a28c1d8e31">,
  "cliente" : "GOMESA S.A.",
  "cuit" : "30404884831",
  "region" : [
    "CENTRO"
  ],
  "direccion" : [ <
    {
      "calle" : "9 de julio",
      "numero" : 1010,
      "localidad" : "TANDIL",
      "provincia" : "BUENOS AIRES" },
    {
      "calle" : "25 de mayo",
      "numero" : 941,
      "piso" : "2do",
      "dto" : "B",
      "localidad" : "CABA" },
    {
      "calle" : "Reconquista",
      "numero" : 654,
      "piso" : "1er",
      "dto" : "A",
      "localidad" : "CABA" } ]
  ]
>
```








































```
> db.reservas.find().limit(3).pretty()
{
  "_id" : ObjectId<"59924e03c049295f1dd5b3d7">,
  "Cliente" : {
    "edad" : 28,
    "profesion" : "Blogger",
    "paisOrigen" : "Chile",
    "nombre" : "Doug Cutting",
    "aerolinea" : "Qatar Airways"
  },
  "fechaReserva" : ISODate<"2014-05-08T12:51:00Z">,
  "mes" : "May",
  "diasHospedaje" : 4,
  "origen" : "Agencia de Viajes",
  "Equipaje" : 8,
  "calificacion" : 2,
  "monedaPago" : "Euro"
}
{
  "_id" : ObjectId<"59924e03c049295f1dd5b3d8">,
  "Cliente" : {
    "edad" : 48,
    "profesion" : "Medico",
    "paisOrigen" : "Australia"
  },
  "fechaReserva" : ISODate<"2010-01-01T20:42:00Z">,
  "mes" : "Ene",
  "diasHospedaje" : 7,
  "origen" : "Portal",
  "Equipaje" : 9,
  "calificacion" : 4,
  "monedaPago" : "Euro"
}
{
  "_id" : ObjectId<"59924e03c049295f1dd5b3d9">,
  "Cliente" : {
    "edad" : 38,
    "profesion" : "Estudiante",
    "paisOrigen" : "España",
    "idiomas" : [
      "Ingles",
      "Español",
      "Portugues"
    ]
  },
  "fechaReserva" : ISODate<"2015-08-21T14:56:00Z">,
  "mes" : "Ago",
  "diasHospedaje" : 1,
  "origen" : "Llamada",
  "Equipaje" : 1,
  "calificacion" : 1,
  "monedaPago" : "Dolar"
}
```


Donde podemos usar MongoDB?

- Aplicaciones donde el crecimiento de registros sea grande y a gran velocidad
- Aplicaciones donde la estructura de los datos varíe sin previo aviso
- Aplicaciones donde distintas entidades se puedan relacionar entre si
- Aplicaciones CMS o blogging
- Debido a sus características escalables y soporte en velocidad es perfecto para Web-analytics y Real - Time analytics.
- Por el comportamiento variable de órdenes de compras y productos es una buena opción para E-Commerce

Ventajas

- En una sola consulta se puede obtener mucha información
- Los conceptos entre un RDBMS y MongoDB no difieren mucho
- Facilidad en la integración con aplicaciones
- Posee variedad de drivers que facilitan su utilización en distintos ambientes
- Permite trabajar JavaScript
- A pesar de ser Open Source, posee un gran soporte y escalabilidad
- Manejo sencillo e intuitivo

| Aug 2017 | Rank | | DBMS | Database Model | Score | | |
|-------------|---|---|--|-------------------|-------------|-------------|-------------|
| | Jul 2017 | Aug 2016 | | | Aug 2017 | Jul 2017 | Aug 2016 |
| 1. | 1. | 1. | Oracle   | Relational DBMS | 1367.88 | -7.00 | -59.85 |
| 2. | 2. | 2. | MySQL   | Relational DBMS | 1340.30 | -8.81 | -16.73 |
| 3. | 3. | 3. | Microsoft SQL Server   | Relational DBMS | 1225.47 | -0.52 | +20.43 |
| 4. | 4. |  5. | PostgreSQL   | Relational DBMS | 369.76 | +0.32 | +54.51 |
| 5. | 5. |  4. | MongoDB   | Document store | 330.50 | -2.27 | +12.01 |
| 6. | 6. | 6. | DB2  | Relational DBMS | 197.47 | +6.22 | +11.58 |
| 7. | 7. |  8. | Microsoft Access | Relational DBMS | 127.03 | +0.90 | +2.98 |
| 8. | 8. |  7. | Cassandra  | Wide column store | 126.72 | +2.60 | -3.52 |
| 9. | 9. |  10. | Redis  | Key-value store | 121.90 | +0.38 | +14.57 |
| 10. | 10. |  11. | Elasticsearch  | Search engine | 117.65 | +1.67 | +25.16 |
| 11. | 11. |  9. | SQLite | Relational DBMS | 110.85 | -3.02 | +0.99 |
| 12. | 12. | 12. | Teradata | Relational DBMS | 79.23 | +0.86 | +5.59 |
| 13. |  14. |  14. | Solr | Search engine | 66.96 | +0.93 | +1.18 |
| 14. |  13. |  13. | SAP Adaptive Server | Relational DBMS | 66.92 | +0.00 | -4.13 |
| 15. | 15. | 15. | HBase | Wide column store | 63.52 | -0.10 | +8.01 |
| 16. | 16. |  17. | Splunk | Search engine | 61.46 | +1.17 | +12.56 |
| 17. | 17. |  16. | FileMaker | Relational DBMS | 59.65 | +1.00 | +4.64 |
| 18. | 18. |  20. | MariaDB  | Relational DBMS | 54.70 | +0.33 | +17.82 |
| 19. | 19. | 19. | SAP HANA  | Relational DBMS | 47.97 | +0.03 | +5.24 |
| 20. | 20. |  18. | Hive  | Relational DBMS | 47.30 | +1.10 | -0.51 |
| 21. | 21. | 21. | Neo4j  | Graph DBMS | 38.00 | -0.52 | +2.43 |
| 22. | 22. |  25. | Amazon DynamoDB  | Document store | 37.62 | +1.16 | +11.02 |
| 23. | 23. |  24. | Couchbase  | Document store | 32.97 | -0.05 | +5.57 |
| 24. | 24. |  23. | Memcached | Key-value store | 29.96 | +1.43 | +2.27 |
| 25. | 25. |  22. | Informix | Relational DBMS | 27.42 | -0.25 | -1.63 |



MongoDB + R



Muchas Gracias!!!

También puedes visitar nuestros blogs

blog.jacagudelo.com

datavictor.wordpress.com